DIAGNOSIS OF DIABETES

The Final Machine Learning Project

Dr. F Keshavarz

Mohammad Mahdi Shafighi

Winter 1403

FEBRUARY 4, 2025

SHAHED-TEHRAN UNIVERSITY
Iran-Tehran

فهرست مطالب

بسمه تعالی

گزارش تحلیل مجموعه داده PIMA Indians Diabetes

"ورژن ها ۱,۱ و ۱,۲ پروژه"

۱ .معرفی مجموعه داده

مجموعه داده **PIMA Indians Diabetes** یکی از مشهورترین دیتاست‌ها در حوزه پزشکی و یادگیری ماشین است که برای **تشخیص دیابت** استفاده می‌شود. این مجموعه شامل اطلاعات پزشکی زنان بالای ۲۱ سال از قبیله **Pima Indians** در ایالات متحده است. هدف اصلی این مجموعه داده، **پیش‌بینی احتمال ابتلا به دیابت** بر اساس متغیرهای پزشکی و بالینی است.

۲ .مشخصات مجموعه داده

- تعداد نمونه‌ها : ۷۶۸
- تعداد ویژگی‌ها : ۸ ویژگی عددی + ۱ برچسب کلاس(Outcome) یا هدف (Target)
- نوع برچسب خروجی (**Target Variable**) **باینری (۰ و ۱)**
  - ۰ :فرد سالم (دیابت ندارد)
  - **۱** :فرد مبتلا به دیابت

```
[ ] df.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 768 entries, 0 to 767
Data columns (total 9 columns):
 #   Column                    Non-Null Count  Dtype  
---  ------                    --------------  -----  
 0   Pregnancies               768 non-null    int64  
 1   Glucose                   768 non-null    int64  
 2   BloodPressure             768 non-null    int64  
 3   SkinThickness             768 non-null    int64  
 4   Insulin                   768 non-null    int64  
 5   BMI                       768 non-null    float64
 6   DiabetesPedigreeFunction  768 non-null    float64
 7   Age                       768 non-null    int64  
 8   Outcome                   768 non-null    int64  
dtypes: float64(2), int64(7)
memory usage: 54.1 KB
```

۳. توضیح ویژگی داده ها

نام ویژگی	توضیحات	محدوده مقادیر
Pregnancies	تعداد بارداری‌ها	۰ تا ۱۷
Glucose	سطح گلوکز خون (mg/dL)	۰ تا ۱۹۹
BloodPressure	فشار خون دیاستولیک (mm Hg)	۰ تا ۱۲۲
SkinThickness	ضخامت پوست (mm) (به عنوان نماینده چربی بدن)	۰ تا ۹۹
Insulin	سطح انسولین سرم (mu U/ml)	۰ تا ۸۴۶
BMI	شاخص توده بدنی (kg/m^2)	۰ تا ۶۷,۱
DiabetesPedigreeFunction	تابع شجره‌نامه دیابت (ریسک ژنتیکی)	۰,۰۸۵ تا ۲,۴۲
Age	سن بیمار (سال)	۲۱ تا ۸۱
Outcome	وضعیت ابتلا به دیابت (۰: خیر، ۱: بله)	۰ یا ۱

۴. بررسی مشکلات احتمالی در داده‌ها

- مقادیر صفر غیرمنطقی: ویژگی‌هایی مانند **Glucose**، **BloodPressure**، **SkinThickness**، **Insulin**و **BMI** نباید مقدار صفر داشته باشند، زیرا مقدار صفر برای این ویژگی‌ها از نظر پزشکی غیرممکن است.
- عدم توزیع یکنواخت داده‌ها: ممکن است برخی ویژگی‌ها دارای **چگالی داده‌های نابرابر** باشند که بر مدل تأثیر بگذارد.
- عدم تعادل کلاس‌ها: بررسی تعداد نمونه‌های **دیابتی (۱) و غیردیابتی (۰)** ضروری است.

۵. روش‌های پیشنهادی برای پیش‌پردازش داده‌ها

- **جایگزینی مقادیر صفر با میانگین یا میانه** در ویژگی‌های پزشکی غیرمنطقی.
- **نرمال‌سازی داده‌ها** (به‌ویژه برای الگوریتم SVM که به مقیاس ویژگی‌ها حساس است).
- **تقسیم داده‌ها** به **۷۰٪ آموزش و ۳۰٪ تست**.

گزارش تحلیل دیتاست و روند پروژه تشخیص دیابت

۱ .مقدمه (روند پروژه)

دیابت یکی از بیماری‌های مزمن و شایع است که تشخیص زودهنگام آن می‌تواند به مدیریت بهتر بیماری و کاهش عوارض آن کمک کند. در این پروژه، با استفاده از **الگوریتم‌های یادگیری ماشین** شامل **ماشین بردار پشتیبان (SVM)** و **جنگل تصادفی(Random Forest)**، سعی می‌کنیم مدل‌هایی برای **تشخیص ابتلا به دیابت** توسعه دهیم. این پروژه شامل مراحل **تحلیل داده، پیش‌پردازش، آموزش مدل، ارزیابی عملکرد و مقایسه الگوریتم‌ها** است.

۲ .تحلیل مجموعه داده(PIMA Indians Diabetes Dataset)

۲,۱ مشخصات مجموعه داده

مجموعه داده **PIMA Indians Diabetes** شامل اطلاعات **۷۶۸ زن بالای ۲۱ سال از قبیله Pima Indians** در ایالات متحده است. این مجموعه داده از **۸ ویژگی پزشکی و یک برچسب خروجی (Outcome)** تشکیل شده است.

نام ویژگی	توضیحات	نوع داده
Pregnancies	تعداد بارداری‌ها	عدد صحیح
Glucose	سطح گلوکز خون	عدد پیوسته
BloodPressure	فشار خون دیاستولیک	عدد پیوسته
SkinThickness	ضخامت پوست	عدد پیوسته
Insulin	سطح انسولین سرم	عدد پیوسته
BMI	شاخص توده بدنی	عدد پیوسته
DiabetesPedigreeFunction	تابع شجره‌نامه دیابت (ریسک ژنتیکی)	عدد پیوسته
Age	سن بیمار	عدد صحیح
Outcome	وضعیت ابتلا به دیابت (۰: سالم، ۱: بیمار)	عدد باینری

۲,۲ بررسی کیفیت داده‌ها

- مقادیر صفر در برخی ویژگی‌ها :در ویژگی‌هایی مانند **Glucose**، **BloodPressure**، **SkinThickness**، **Insulin**و**BMI** ، مقدار صفر غیرمنطقی است و باید **اصلاح** شود.
- توزیع نامتعادل کلاس‌ها :ممکن است داده‌ها **توزیع نامتوازن** داشته باشند که بر عملکرد مدل‌ها تأثیر بگذارد.
- تفاوت در مقیاس داده‌ها :برخی ویژگی‌ها دارای بازه‌های متفاوتی هستند که می‌تواند روی عملکرد مدل‌هایی مانند **SVM** تأثیر بگذارد.

۳ .مراحل پردازش داده‌ها

۳,۱ پیش‌پردازش داده‌ها

I. حذف یا جایگزینی مقادیر غیرمنطقی:

- مقادیر صفر در ویژگی‌های پزشکی با **میانگین یا میانه** جایگزین می‌شوند.

II. استانداردسازی داده‌ها:

- داده‌ها با استفاده از **StandardScaler** استاندارد می‌شوند تا مقیاس‌بندی ویژگی‌ها هماهنگ شود.

III. تقسیم داده‌ها:

- داده‌ها به دو بخش **۷۰٪ برای آموزش و ۳۰٪ برای تست** تقسیم می‌شوند.

((همانطور که در شکل زیر مشاهده می شود ، مقادیر غیر منطقی و یا صفر با میانه جایگزین شده اند .))

```
df.head(30)
```

	Pregnancies	Glucose	BloodPressure	SkinThickness	Insulin	BMI	DiabetesPedigreeFunction	Age	Outcome
0	6	148	72	35	125	33.6	0.627	50	1
1	1	85	66	29	125	26.6	0.351	31	0
2	8	183	64	29	125	23.3	0.672	32	1
3	1	89	66	23	94	28.1	0.167	21	0
4	4	137	40	35	168	43.1	2.288	33	1
5	5	116	74	29	125	25.6	0.201	30	0
6	3	78	50	32	88	31.0	0.248	26	1
7	10	115	72	29	125	35.3	0.134	29	0
8	2	197	70	45	543	30.5	0.158	53	1
9	8	125	96	29	125	32.3	0.232	54	1
10	4	110	92	29	125	37.6	0.191	30	0
11	10	168	74	29	125	38.0	0.537	34	1
12	10	139	80	29	125	27.1	1.441	57	0
13	1	189	60	23	846	30.1	0.398	59	1
14	5	166	72	19	175	25.8	0.587	51	1
15	7	100	72	29	125	30.0	0.484	32	1

۴ .پیاده‌سازی و آموزش مدل‌ها

۴,۱ مدل **SVM** ماشین بردار پشتیبان

- دو نوع کرنل بررسی می‌شود:
  - **کرنل خطی**
  - **کرنل RBF یا شعاعی**
- **تنظیم هایپرپارامترها** با **Grid Search** انجام می‌شود.

۴,۲ مدل **Random Forest** جنگل تصادفی

- از **۱۰۰ درخت تصمیم‌گیری (n_estimators=100)** استفاده می‌شود.
- بررسی اثر **تعداد درخت‌ها** بر دقت مدل.

```
# rf_model = RandomForestClassifier(n_estimators=100, random_state=42)
# rf_model.fit(X_train, y_train)

# Random Forest model
# rf_model = RandomForestClassifier(n_estimators=110, random_state=42) ## --> n_estimators = 110
# rf_model = RandomForestClassifier(n_estimators=90, random_state=42) ## --> n_estimators = 90
# rf_model = RandomForestClassifier(n_estimators=95, random_state=42) ## --> n_estimators = 95
# rf_model = RandomForestClassifier(n_estimators=200, random_state=42) ## --> n_estimators = 200
rf_model = RandomForestClassifier(n_estimators=300, random_state=42) ## --> n_estimators = 300     **
# rf_model = RandomForestClassifier(n_estimators=1000, random_state=42) ## --> n_estimators = 1000
# rf_model = RandomForestClassifier(n_estimators=500, random_state=42) ## --> n_estimators = 500
# rf_model = RandomForestClassifier(n_estimators=310, random_state=42) ## --> n_estimators = 310


rf_model.fit(X_train, y_train)
rf_probs = rf_model.predict_proba(X_test)[:, 1]
```

Make predictions on the test set

```
[ ] y_pred_rf = rf_model.predict(X_test)
```

```
[ ] accuracy_rf = accuracy_score(y_test, y_pred_rf)
    print(f"Accuracy of the Random Forest model: {accuracy_rf}")
    # Accuracy of the Random Forest model: 0.7597402597402597   ## ---> the first result

    # n_estimator Changes:
    ## Change 1 :(n_estimators=110)  Accuracy of the Random Forest model: 0.7467532467532467
    ## Change 2 :(n_estimators=90)   Accuracy of the Random Forest model: 0.7532467532467533
    ## Change 3 :(n_estimators=95)   Accuracy of the Random Forest model: 0.7597402597402597
    ##                 as samev the default                              0.7597402597402597
    ## Change 4 :(n_estimators=200)  Accuracy of the Random Forest model: 0.7662337662337663  (growth)
    ## Change 5 :(n_estimators=300)  Accuracy of the Random Forest model: 0.7792207792207793  (growth more)                    **
    ## Change 6 :(n_estimators=1000) Accuracy of the Random Forest model: 0.7662337662337663  (decreased significantly == 200)
    ## Change 6 :(n_estimators=500)  Accuracy of the Random Forest model: 0.7727272727272727  (increased significantly <= 300)
    ## Change 6 :(n_estimators=310)  Accuracy of the Random Forest model: 0.7727272727272727  (increased significantly <= 300)

Accuracy of the Random Forest model: 0.7792207792207793
```

۵ .ارزیابی و مقایسه مدل‌ها

- محاسبه **معیارهای عملکرد** برای هر مدل:
  - **دقت Accuracy**
  - **دقت مثبت Precision**
  - **بازخوانی مثبت Recall**
  - **F1-Score**
  - **ROC Curve و AUC**
- مقایسه دو مدل بر اساس معیارهای فوق و تحلیل نقاط ضعف و قوت هر یک.

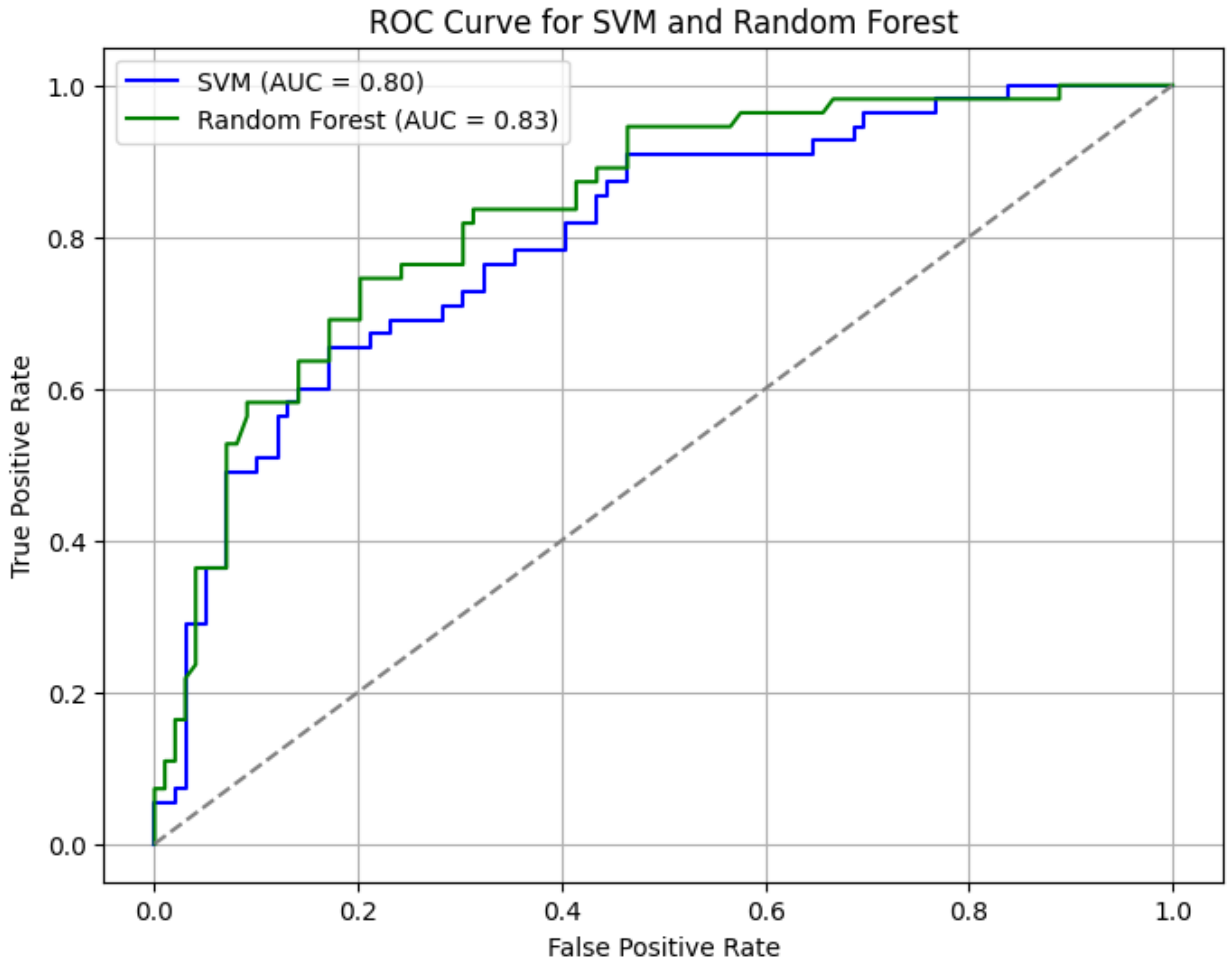

۶ .ارائه نتایج و تحلیل نهایی

۶,۱ نتایج و تفسیر

- بررسی اینکه کدام مدل **دقت بیشتری دارد**؟

طبق نتایج، مدل **Random Forest** دارای دقت بیشتری نسبت به مدل‌های دیگر است. مقدار دقت آن برابر با **0.779** است، در حالی که مدل ***SVM*** دقت **0.766** دارد.

- بررسی عملکرد مدل‌ها در **شناسایی بیماران دیابتی**.

معیار ***Recall*** مهم است. اگر ***Recall*** مدل Random Forest بیشتر باشد، نشان‌دهنده این است که این مدل بیماران بیشتری را به درستی شناسایی کرده است. باید مقادیر Recall را بررسی کنیم.

- تحلیل اینکه آیا **Random Forest به برخی ویژگی‌ها حساس‌تر است**؟

باید بررسی اهمیت ویژگی‌ها (Feature Importance) در مدل Random Forest انجام شود. اگر وزن بیشتری به برخی ویژگی‌ها داده شده باشد، می‌توان گفت این مدل به آن ویژگی‌ها حساس‌تر است.

```
Best Hyperparameters: {'C': 100, 'gamma': 0.001, 'kernel': 'rbf'}
Accuracy of the optimized SVM model: 0.7792207792207793
              precision    recall  f1-score   support

           0       0.82      0.85      0.83        99
           1       0.71      0.65      0.68        55

    accuracy                           0.78       154
   macro avg       0.76      0.75      0.76       154
weighted avg       0.78      0.78      0.78       154
```

مربوط به مدل بهینه شده SVM

```
Best Hyperparameters for Random Forest: {'max_depth': None, 'min_samples_leaf': 4, 'min_samples_split': 2, 'n_estimators': 500}
Accuracy of the optimized Random Forest model: 0.7662337662337663
              precision    recall  f1-score   support

           0       0.82      0.81      0.82        99
           1       0.67      0.69      0.68        55

    accuracy                           0.77       154
   macro avg       0.75      0.75      0.75       154
weighted avg       0.77      0.77      0.77       154
```

مربوط به مدل بهینه جنگل تصادفی

۶,۲ پیشنهادات برای بهبود مدل

- استفاده از **روش‌های افزایش داده‌ها (Data Augmentation)** برای مقابله با عدم توازن داده‌ها.
- بررسی دیگر الگوریتم‌های یادگیری ماشین مانند **شبکه‌های عصبی مصنوعی.(ANN)**
- استفاده از Feature Selection برای بهینه‌سازی ویژگی‌ها
- تست مدل‌های ترکیبی (Ensemble Methods)
- بهینه‌سازی هایپرپارامترها برای مدل SVM

۷ .خروجی‌های نهایی مورد انتظار

- ✓ **کدهای اجرایی در محیط Google Colab**
- ✓ **گزارش PDF شامل تحلیل داده و نتایج مقایسه مدل‌ها**
- ✓ **نمودارهای مربوط به ارزیابی مدل‌ها Confusion Matrix ، ROC Curve،**
- ✓ **نتیجه‌گیری درباره بهترین مدل برای تشخیص دیابت**

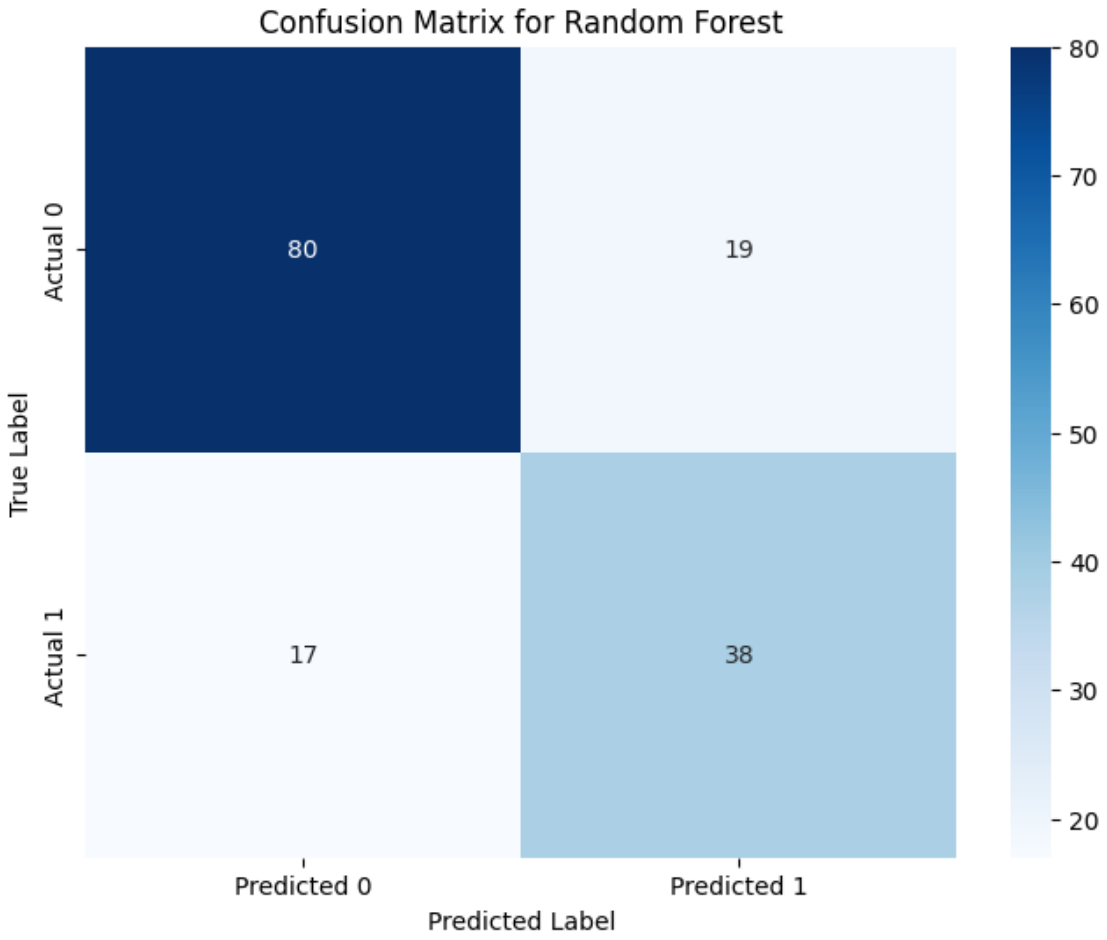

تحلیل مزایا و معایب:

- **Random Forest معمولاً دقت بالاتر و مقاومت در برابر نویز دارد، اما محاسبات سنگین‌تر است.**
- **SVM در برخی داده‌ها عملکرد بهتری دارد، اما به تنظیمات حساس‌تر است.**

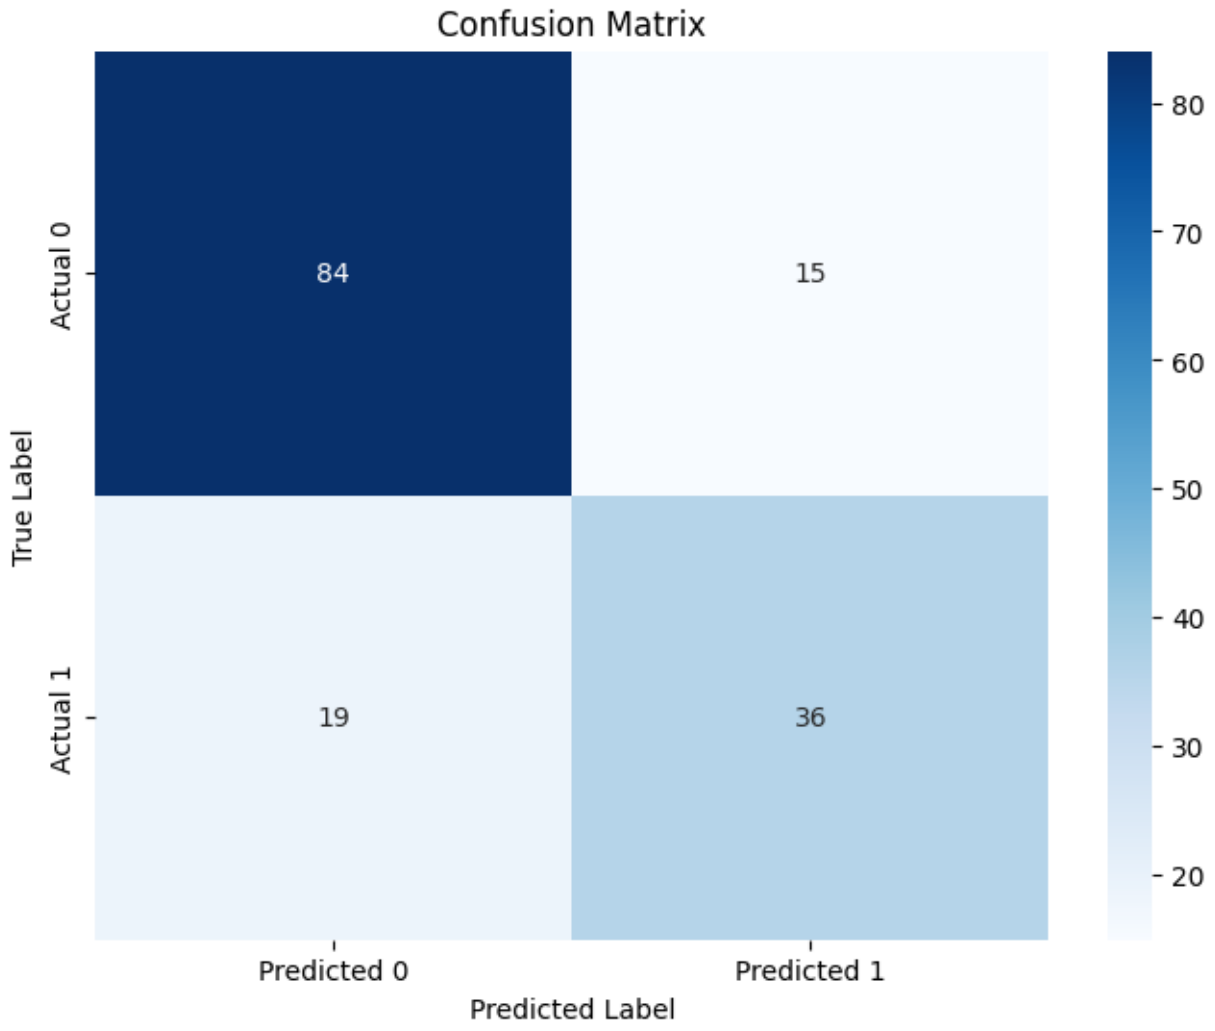

۸ .نتیجه‌گیری

این پروژه با هدف **مقایسه عملکرد دو الگوریتم SVM و Random Forest در تشخیص دیابت** انجام می‌شود. پس از **تحلیل داده‌ها، پیش‌پردازش، آموزش مدل‌ها، و ارزیابی عملکرد**، مشخص می‌شود که کدام مدل **عملکرد بهتری در تشخیص بیماران دیابتی دارد** و چگونه می‌توان مدل‌ها را بهبود داد.

" همچنین در ورژن ۱,۳ Grid Search هم بررسی خواهد شد. "

با تشکر از زحمات دکتر کشاورز